

Anteproyecto de Trabajo de Final de Máster

Diseño e implementación de un asistente conversacional para el soporte a analistas de datos en entornos MongoDB

Autor: Lucas Silva Pérez

Director: Alejandro Martín

Identificador: 6.4

Marzo 2026

Índice

1. Introducción y motivación	3
2. Objetivos	3
3. Estado del arte	4
3.1. Asistentes conversacionales basados en LLM	4
3.2. Consulta en lenguaje natural sobre bases de datos NoSQL	4
3.3. Herramientas de soporte al analista de datos	5
4. Metodología	5
4.1. Diseño del sistema	5
4.2. Implementación	6
4.3. Evaluación	6

1. Introducción y motivación

MongoDB es un sistema de gestión de bases de datos no relacionales, perteneciente a la categoría conocida como NoSQL. Son sistemas de almacenamiento que no utilizan tablas, filas ni esquemas fijos (como si lo hacen las bases de datos basadas en SQL), permitiendo gestionar grandes volúmenes de datos no estructurados o semi-estructurados con alta escalabilidad y flexibilidad. Utilizan modelos como documentos (JSON), clave-valor, grafos o columnas anchas, ideales para aplicaciones modernas, redes sociales y Big Data. *MongoDB Query Language* (MQL) es el lenguaje utilizado para consultar y manipular datos en MongoDB. Permite realizar operaciones como buscar, insertar, actualizar o eliminar documentos dentro de una base de datos. A diferencia de lenguajes como SQL, que trabajan con tablas y filas, MQL opera sobre documentos en formato similar a JSON organizados en colecciones. Las consultas se expresan mediante estructuras tipo objeto, usando pares clave-valor y operadores específicos.

Por ejemplo, una consulta en MQL para encontrar usuarios de 25 años podría escribirse así:

```
db.users.find({ age: 25 })
```

El lenguaje también incluye operadores para condiciones más complejas, como comparaciones (*gt*, *lt*), lógica (*and*, *or*) o filtrado por campos dentro de documentos anidados. Esto permite realizar consultas flexibles sobre datos con estructura variable, una característica típica de las bases de datos NoSQL.

En general, MongoDB sigue siendo un sistema muy usado, pero muchos analistas no dominan el lenguaje MQL, aquí es donde entra nuestro proyecto, ya que los LLMs han demostrado una gran capacidad para generar código, la combinación de un *Large Language Model* (LLM) para MQL nos abre la oportunidad para este TFM.

2. Objetivos

La idea central es construir un chatbot o asistente al que un analista de datos le pueda hacer preguntas en español (o inglés) y el sistema las traduzca automáticamente a consultas MongoDB, las ejecute, y devuelva los resultados de forma comprensible. Por ejemplo: el analista escribe "¿cuántos pedidos se hicieron en enero con importe superior a 500€?" el sistema genera y ofrece la query correspondiente sin que el analista tenga que ser un experto MQL. El núcleo técnico gira en torno a un LLM (GPT-4, Claude, Llama, etc.) al que le das contexto sobre el esquema de tu base de datos y le pides que genere la query. Encima de eso construyes una capa conversacional que mantiene el hilo del diálogo, gestiona errores y presenta los resultados.

3. Estado del arte

3.1. Asistentes conversacionales basados en LLM

En los últimos años, los LLMs han demostrado una gran capacidad para comprender lenguaje natural y generar texto estructurado, incluyendo código. Modelos como GPT, Claude o LLaMA han sido utilizados para construir asistentes conversacionales capaces de responder preguntas, generar documentación o ayudar en tareas técnicas.

Una de las aplicaciones más relevantes de estos modelos es la generación automática de código a partir de descripciones en lenguaje natural. Diversos trabajos han mostrado que los LLM pueden producir consultas a bases de datos, scripts o fragmentos de programas si se les proporciona suficiente contexto sobre el problema. Esto ha impulsado el desarrollo de asistentes que ayudan a desarrolladores y analistas a interactuar con sistemas complejos mediante lenguaje natural.

Además, la aparición de marcos de desarrollo para aplicaciones basadas en LLM, como LangChain o LlamaIndex, ha facilitado la creación de agentes conversacionales capaces de conectarse a bases de datos, ejecutar consultas y procesar resultados. Estas herramientas permiten integrar modelos de lenguaje con fuentes de datos externas, lo que abre la puerta a sistemas de consulta automatizada.

3.2. Consulta en lenguaje natural sobre bases de datos NoSQL

La consulta de bases de datos mediante lenguaje natural es un área de investigación que existe desde hace décadas, tradicionalmente centrada en bases de datos relacionales y en la traducción automática de preguntas a SQL. Con la aparición de los LLM, esta línea de trabajo ha experimentado un nuevo impulso, ya que los modelos actuales son capaces de generar consultas de forma mucho más flexible que los enfoques clásicos basados en reglas.

En el caso de las bases de datos NoSQL, como MongoDB, el problema presenta algunas particularidades. A diferencia de SQL, donde el esquema suele estar bien definido, los sistemas NoSQL permiten estructuras de datos más flexibles. Esto puede dificultar la generación automática de consultas, ya que el sistema necesita conocer o inferir la estructura de los documentos almacenados.

Aun así, algunos trabajos recientes han explorado el uso de LLM para generar consultas en lenguajes como MQL a partir de preguntas en lenguaje natural. Estos enfoques suelen basarse en proporcionar al modelo información sobre el esquema de la base de datos o ejemplos de consultas para guiar la generación.

3.3. Herramientas de soporte al analista de datos

En el ámbito profesional existen diversas herramientas orientadas a facilitar el trabajo de los analistas de datos. Plataformas de *business intelligence* y herramientas de exploración de datos permiten construir consultas, visualizar resultados y generar informes sin necesidad de programar directamente.

Más recientemente, algunos proveedores han comenzado a integrar capacidades de inteligencia artificial en sus productos, permitiendo a los usuarios formular preguntas en lenguaje natural sobre los datos. Estos sistemas suelen traducir la pregunta a una consulta interna, ejecutarla y mostrar los resultados en forma de tablas o visualizaciones.

Sin embargo, muchas de estas soluciones están principalmente orientadas a bases de datos relacionales o a entornos muy controlados. En el caso de bases de datos NoSQL como MongoDB, todavía existe margen para desarrollar asistentes que ayuden a los analistas a formular consultas complejas sin necesidad de dominar completamente el lenguaje MQL. En este contexto, el uso de LLM como intermediarios entre el usuario y la base de datos representa una línea de trabajo prometedora.

4. Metodología

El desarrollo del proyecto seguirá un enfoque iterativo e incremental, organizado en tres fases principales: diseño del sistema, implementación y evaluación. Esta aproximación permite validar decisiones técnicas de forma temprana y ajustar el diseño en función de los resultados obtenidos en cada iteración.

4.1. Diseño del sistema

La arquitectura del asistente se articula en torno a tres componentes principales. El primero es el módulo de comprensión del lenguaje natural, responsable de interpretar la consulta del usuario y extraer su intención. El segundo es el módulo de generación de queries, que traduce dicha intención a una consulta válida en MQL, haciendo uso de un LLM. El tercero es la interfaz conversacional web, a través de la cual el usuario introduce sus preguntas y recibe los resultados. La comunicación entre el LLM y MongoDB se gestionará mediante un mecanismo de *prompting* estructurado que incluirá, en cada petición, el esquema de la colección consultada y un conjunto de ejemplos representativos. Esta técnica, conocida como *few-shot prompting*, ha demostrado mejorar significativamente la precisión en tareas de generación de código estructurado. En cuanto a la elección del modelo de lenguaje, se realizará un análisis comparativo de las opciones disponibles (modelos accesibles vía API y modelos ejecutables en local)

atendiendo a criterios de precisión, coste, latencia y privacidad de los datos. La decisión final se tomará al inicio de la fase de implementación

4.2. Implementación

El sistema se desarrollará en Python, con la idea de crear una interfaz web construida con un framework ligero. La implementación se dividirá en dos etapas. En la primera se construirá un prototipo funcional sobre un esquema de base de datos fijo, con el objetivo de validar el flujo completo desde la entrada del usuario hasta la ejecución de la query y la presentación del resultado. En la segunda etapa se generalizará el sistema para que sea capaz de inferir el esquema de cualquier colección MongoDB de forma dinámica, sin requerir configuración manual. Respecto al conjunto de datos, se evaluará el uso de un dataset público de referencia o, en su defecto, se diseñará un dataset sintético que cubra los patrones de consulta más habituales en entornos analíticos.

4.3. Evaluación

La evaluación del sistema se realizará con corrección funcional, se construirá un benchmark de consultas en lenguaje natural emparejadas con su query MongoDB esperada, y se medirá el porcentaje de queries generadas que producen el resultado correcto.